

1D-CNN LSTM 기반의 회전기계 고장 진단 기법

Anomaly Detection based on 1D-CNN LSTM for Rotating Machine

이대희¹⁾, 김세원²⁾, 유정민³⁾, 정예원⁴⁾, 채서윤⁵⁾, 이채규⁶⁾, 추현승⁷⁾, 정종필⁸⁾

Dae-Hee Lee*, Se-Won Kim**, Jung-Min Yoo***, Ye-Won Jeong****, Seo-Yoon Chae*****
Lee******, Hyun-Seung Choo******, Jong-Pil Jeong*****

hahalee98@kakao.com, dkssud457@naver.com, bloom421@naver.com, mn07086@naver.com, hpandtcos@naver.com,
leechgyu@skku.edu, choo@skku.edu, jpjeong@skku.edu

요약

제조업은 현재 4차 산업혁명의 흐름 속에서 빠르게 발전하며, 이러한 변화에 따라 회전체의 중요도가 크게 증가하고 있다. 본 논문에서는 1D-CNN LSTM(One Dimension Convolution Neural Network Long Short-Term Memory) 기반의 회전기계 고장 진단 기법을 제안한다. 1D-CNN LSTM 모델은 딥러닝 기반 모델로 딥러닝은 다량의 데이터를 학습하여 복잡한 패턴을 인식하고 예측이 가능하며, 제안한 모델을 활용해 각 고장 유형별 95.6%, 71.4%, 97.4%의 고장 진단 정확도를 나타냈다. 이를 통해 본 논문에서 제안하는 모델을 활용해 생산 공정의 중단을 미리 방지하고, 기업의 생산 효율과 경쟁력을 향상할 수 있다.

키워드 : Anomaly Detection, 1D-CNN LSTM, Rotating Machine, Deep Learning

I. 서론

최근 4차 산업혁명에 따라 제조업은 대용량, 초고속, 저전력을 키워드로 빠르게 발전하고 있다. 이러한 변화 속에서 회전체는 제조업에 없어서 안 되는 핵심 부품 중 하나로 제조업이 발전함에 따라 회전체의 가치와 중요도 또한 높아지고 있다. 회전체는 다양한 기계와 장비에서 중추적인 역할을 하는데, 이러한 회전체에 고장이 발생할 경우 전체 생산 공정에 큰 차질이 발생하고 이는 막대한 손실로 연결된다. 회전체의 고장을 딥러닝을 통해 초기에 진단한다면 기업의 손실을 최소화하며 동시에 생산 효율을 높일 수 있다. 이는 산업적인 측면과 경제적인 측면에서 큰 장점이 될 것이다.

최근 회전체의 고장을 진단하기 위해 DNN[1], CNN[2], RNN[3] 등 딥러닝을 활용한 다양한 연구가 진행되고 있다.

딥러닝은 다량의 데이터를 학습하여 복잡한 패턴을 인식하고 예측할 수 있으므로, 회전체의 소음, 진동[4] 등의 데이터를 활용하여 고장을 초기에 진단하는 것이 가능하다. 본 논문은 질량 불균형 상태[5], 지지 불량 상태에서 1D-CNN LSTM(One Dimension Convolution Neural Network Long Short-Term Memory) 딥러닝 모델을 활용한 회전기계 고장 진단 기법을 제안한다. 회전기계의 고장 진단 기법을 활용해 생산 공정의 중단을 미리 방지해 기업의 생산 효율과 경쟁력을 향상할 수 있다.

본 논문은 다음과 같은 순서로 구성되어 있다. II장에서는 본 논문에서 제안한 회전기계 고장 진단 시스템의 구조, 실험 데이터, 데이터 유형, 데이터 전처리 과정을 소개하고 III장에서는 실험 결과를 이야기한다. IV장에서는 결론으로 마무리한다.

II. 본문

본 논문은 KAMP에서 제공한 회전기계 고장유형 AI 테이터셋[8]을 활용했다. 그럼 1은 분석에 사용한 Rotor Testbed로 시그널링크[9]의 ERA(Educational Rotor Application) Test Station이며, 본 모델은 소음-진동 test에 적합한 기능을

- 1) 성균관대학교 전자전기컴퓨터공학과
- 2) 성균관대학교 건설환경공학부
- 3) 성균관대학교 건설환경공학부
- 4) 성균관대학교 시스템경영공학과
- 5) 성균관대학교 전자전기공학부
- 6) 성균관대학교 스마트팩토리융합학과 (공동 교신저자)
- 7) 성균관대학교 전자전기컴퓨터공학과 (공동 교신저자)
- 8) 성균관대학교 스마트팩토리융합학과 (공동 교신저자)

제공한다.



그림 1. Rotor Testbed

Rotor Testbed는 Controller Module, BLDC Motor(Bushed less DC Motor), Disks의 3가지 기본 구성으로 이루어져 있다. Controller Module은 Disks의 회전속도인 RPM을 조절할 수 있는 장치로 본 실험에서는 1,500 RPM인 진동 데이터를 수집하였다. BLDC Motor는 브러시가 제거된 형태로 출력을 세밀하게 조절할 수 있는 장점이 있는 모터다. Disks의 경우 36개의 볼트 체결 구멍이 있으며 270도 위치에 볼트를 하나 체결하여 질량의 불균형을 구현하였다.

본 논문에서 그림 2는 본 논문에서 제안한 1D-CNN LSTM 기반의 회전기계 고장 진단 시스템의 구조다. 1D CNN 모델[6]은 시계열 데이터의 패턴을 효과적으로 인식하고 추출한다. 일정 시간 동안의 주기적 패턴, 주파수 구성 요소를 파악하는 데 유용하다. LSTM 모델[7]은 시퀀스 데이터의 장기적인 의존성을 학습하는데 뛰어나며 이는 시계열 데이터 처리에 유리한 모델이다. 따라서 1D-CNN LSTM 모델은 시계열 데이터 처리에 효과적이라는 장점을 가지고 있다.

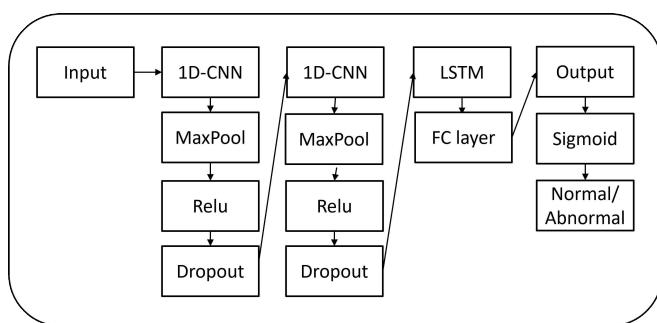


그림 2. 1D-CNN LSTM Structure

III. 실험 결과

실험을 위해 정상 상태(Normal), Disk에 볼트를 하나 체결한 질량 불균형(Unbalance), 기계의 나사 하나를 약하게 고정하여 정렬 불량을 가정한 지지 불량(Mechanical Looseness), 그리고 질량 불균형과 지지 불량을 함께 실험한 데이터, 총 4

가지 유형의 실험 데이터셋을 활용했다. 이 데이터셋들은 140초 동안 수집한 데이터로 선형보간, 필터링, 정규화 같은 데이터 전처리 과정을 사용했으며 Training Data는 240,000개, Validation Data는 80,000개, Test Data는 80,000개의 데이터셋으로 분류하여 실험을 진행했다.

본 논문은 4가지 유형의 실험 데이터셋에 관하여 다중 분류 실험을 진행하는 것이 아닌 각 유형의 데이터에 대해 이진 분류 실험을 진행했다. 이진 분류는 다중 분류보다 학습이 빨라 해당 오류 유형에 가장 적합한 모델을 개발하는 데 유용하며, 실제 제조 현장에서는 실시간 고장 감지를 해야하는데 이를 위해서는 학습하는 데 시간이 오래 걸리지 않는 상대적으로 가벼운 모델이 적합하다. 또한 현장에서 일어나는 문제의 대부분은 질량 불균형 부분이기 때문에 이 부분에 집중하여 분류 모델을 설정했다. 각 실험에 대한 결과는 그림 3, 4, 5와 같은 Confusion Matrix를 통해 나타냈다. 정상 데이터와 고장유형 3가지 데이터셋에 대하여 95.6%, 71.4%, 97.4%의 고장 진단 정확도를 확인할 수 있었다.

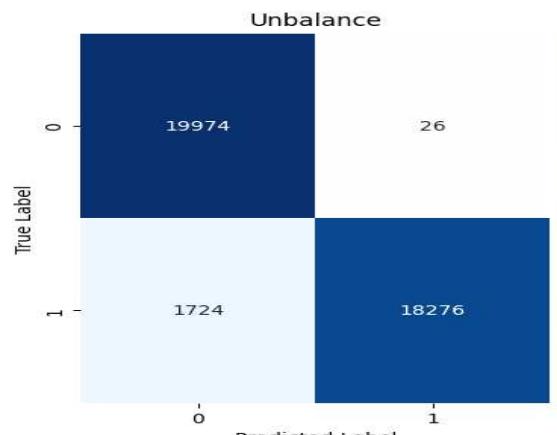


그림 3. Normal vs. Unbalance

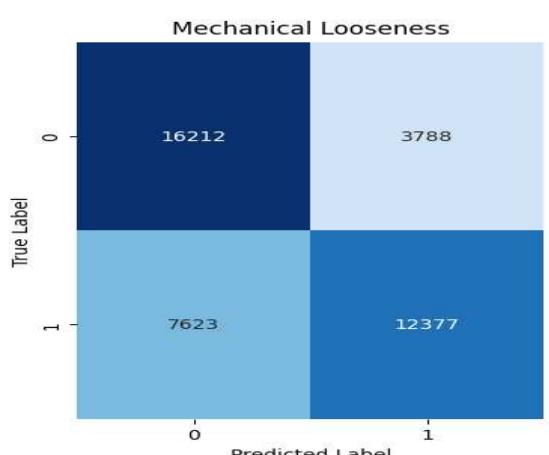


그림 4. Normal vs. Mechanical Looseness

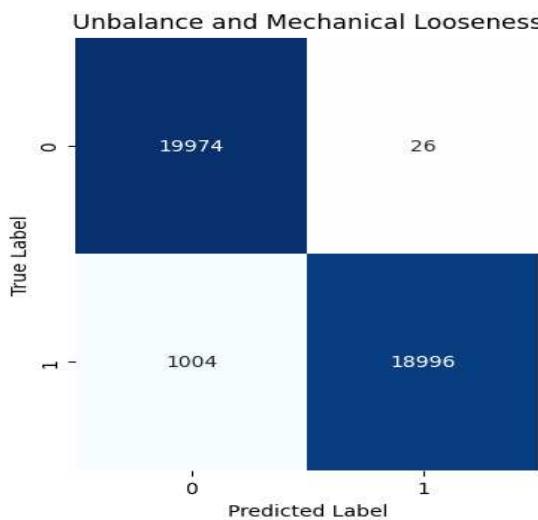


그림 5. Normal vs. Unbalance and Mechanical Looseness

IV. 결론

본 논문에서는 KAMP에서 제공한 회전기계 고장유형 AI 데이터셋을 활용하여 1D-CNN LSTM 기반의 회전기계 고장 진단 시스템을 제안한다. 1D-CNN은 시계열 데이터의 패턴을 효과적으로 인식하며, LSTM은 시퀀스 데이터의 장기적인 의존성을 학습하는 능력을 갖추고 있다. 1D-CNN과 LSTM 모델을 동시에 사용하여 시계열 데이터 처리에 매우 효과적임을 나타냈다.

본 연구의 실험 결과, 정상 데이터와 3가지 유형의 고장 데이터셋에 대하여 이진 분류를 한 결과 각각 95.6%, 71.4%, 97.4%의 정확도로 고장을 진단할 수 있었다. 특히 질량 불균형과 같이 제조 현장에서 자주 발생하는 문제에 대해 집중하여 분류 모델을 설정함으로써 실제 현장 적용 시 큰 도움이 될 것으로 예상된다. 질량 불균형(Unbalance) 고장 데이터에 대해 71.4%의 다소 낮은 정확도가 나타난 이유는 실험 환경 제작을 할 때 Rotor Testbed를 고정하는 4가지 나사 중 하나를 느슨하게 고정하여 질량 불균형 데이터를 추출했는데, 이 실험을 통해 발생한 진동 데이터의 폭 변화가 미세하여 타고장 데이터보다 높은 정확도를 나타내지 않았다고 예상할 수 있다. 향후 이 고장 유형에 대하여 이진 분류가 아닌 다중 분류로 추가적인 연구를 진행할 계획이다.

참고 문헌

- [1] Huang Yi, Sun Shiyu, Duan Xiusheng, and Chen Zhibang, "A study on Deep Neural Networks framework," IEEE Advanced Information Management, Communicates, Electronic and Automation Control Conference (IMCEC), pp. 1519–1522, 2016.
- [2] Keiron O'Shea and Ryan Nash, "An Introduction to Convolutional Neural Networks", arXiv:1511.08458, 2015.
- [3] Wojciech Zaremba, Ilya Sutskever, and Oriol Vinyals, "Recurrent Neural Network Regularization," arXiv:1409.2329, 2014.
- [4] W. Chung, S. Lee, T. Chung, and J. Lee, "Fault Diagnosis of a Pump by Using Vibrational Signals," Proceedings of the KSME Conference, pp.590–595, 2001.
- [5] Daehee Lee, Hyunseung Choo, and Jongpil Jeong, "Anomaly Detection Based on 1D-CNN-LSTM Auto-Encoder for Bearing Data," WSEAS Transactions on Information Science and Applications, Volume 20, pp.1–6, January 2023.
- [6] Serkan Kiranyaz, Onur Avci, Osama Abdeljaber, Turker Ince, Moncef Gabbouj, and Daniel J. Inman, "1D Convolutional Neural Networks and Applications: A Survey," Mechanical Systems and Signal Processing, Vol. 151, 2021.
- [7] Ralf C. Staudemeyer and Eric Rothstein Morris, "Understanding LSTM -- a tutorial into long short-term memory recurrent neural networks," arXiv:1909.09586, 2019.
- [8] 중소벤처기업부, Korea AI Manufacturing Platform(KAMP), "회전기계 고장유형 AI 데이터셋," <https://www.kamp-ai.kr>, 2021.
- [9] Signallink, "Educational Rotor Application Test Station," <http://www.signallink.co.kr>.

* 본 연구는 교육부와 한국연구재단의 지원으로 수행된 3 단계 산학연협력 선도대학 육성사업 (LINC 3.0)의 연구 결과임.